

Data Science

Hoja de Ejercicios de Series de Tiempo

En esta hoja de ejercicios trabajará con el dataset de la temperatura promedio de la tierra desde 1950 hasta 2026 en la región de Guatemala. En canvas puede encontrar el conjunto de datos. En estos datos está la temperatura promedio por año de varias capas de la tierra.

EJERCICIO 1. Cargue el archivo con R o con Python y explórelo un poco, ¿Cuáles son los extremos de la temperatura promedio de la tierra? ¿y por capa? ¿Como ha sido la tendencia, ha bajado, subido, se ha mantenido constante alrededor de un valor?


Los extremos de la temperatura promedio de la tierra son:

- Mínimo: 18.97°C
- Máximo: 28.69 °C

Los extremos de la temperatura por capa son:

- Temperatura a 2m (temperature_2m_c): Min = 18.97 °C, Max = 28.69 °C
- Temperatura de la superficie (skin_temperature_c): Min = 19.15 °C, Max = 29.74 °C
- Suelo Capa 1 (soil_temperature_layer_1_c): Min = 19.84 °C, Max = 30.29 °C
- Suelo Capa 2 (soil_temperature_layer_2_c): Min = 19.96 °C, Max = 29.80 °C
- Suelo Capa 3 (soil_temperature_layer_3_c): Min = 20.49 °C, Max = 28.35 °C
- Suelo Capa 4 (soil_temperature_layer_4_c): Min = 21.57 °C, Max = 26.88 °C

Al observar la serie de tiempo y se hizo el cálculo de media móvil se puede que la tendencia ha subido. Aproximadamente desde 1950 hasta finales de los 70s, la temperatura se mantuvo de manera constante. Pero a partir de la década de 1980, se evidencia una tendencia creciente y sostenida, alcanzando los picos más altos en los últimos años del registro (hacia 2023-2026).



EJERCICIO 2. Divida el conjunto en entrenamiento y prueba. Deje los últimos 36 meses para probar.

Con la division de datos, estos quedaron distribuidos de la siguiente manera:

- Total de registros: 918 meses.
- Conjunto de Entrenamiento (Train): 882 meses (desde el 01 de Enero de 1950 hasta el 01 de Junio de 2023).
- Conjunto de Prueba (Test): 36 meses (desde el 01 de Julio de 2023 hasta el 01 de Junio de 2026).

EJERCICIO 3. Conviértalo en una serie de tiempo y analícela (explique sus razonamientos), para esto:

a) Explore la serie, descompóngala en componentes y analícelos

Como las oscilaciones (amplitud) de la temperatura mes a mes no parecen hacerse más grandes en proporción al aumento de la tendencia global, lo más adecuado es aplicar una descomposición aditiva.

Análisis de los componentes:

- Observación (temperature_2m_c): Es la serie original, donde se aprecian picos anuales marcados.
- Tendencia (Trend): Al extraer el ruido y la estacionalidad, confirmamos visualmente que la temperatura ha ido en aumento, con un alza particularmente pronunciada a partir de los años 80 y 90.
- Estacionalidad (Seasonal): El patrón es perfectamente regular y predecible a lo largo de los 12 meses del año (ciclos de subida y bajada repetitivos).
- Residuos (Resid): Es el ruido sobrante o variaciones irregulares. Vemos que los valores residuales oscilan uniformemente alrededor del 0, lo que nos indica que el modelo aditivo captura bastante bien la estructura.

b) Determine si tiene tendencia

La serie tiene tendencia. Como observamos tanto en el gráfico de medias móviles del Ejercicio 1 como en el componente "Trend" de nuestra gráfica de descomposición actual, existe una tendencia secular al alza. El nivel general de la serie de tiempo está aumentando con el paso de las décadas.

c) Determine si es estacionaria, recuerde que debe ser estacionaria en media y en varianza

Para determinar si la serie es estacionaria, evaluamos visualmente y con pruebas estadísticas si su media y su varianza se mantienen constantes en el tiempo:


- Estacionaria en media: Al observar la media móvil de 12 meses (línea roja superior), es evidente que el nivel sube con los años. No es estacionaria en media debido a la presencia de la tendencia creciente.
- Estacionaria en varianza: La varianza móvil (línea verde inferior) oscila regularmente, pero su rango histórico general se mantiene bastante horizontal (no se "abre" con forma de megáfono con el paso del

tiempo). Podríamos decir que su varianza es estable, pero la falta de estabilidad en la media afecta a la serie completa.

Confirmación mediante Pruebas Estadísticas:

- Prueba ADF (Dickey-Fuller Aumentada): Obtuvimos un p-valor de 0.00035. La prueba ADF detecta fuerte reversión (por los ciclos anuales constantes), pero para modelos paramétricos necesitamos corroborar la tendencia.
- Prueba KPSS: A diferencia de ADF, la hipótesis nula de KPSS es que la serie sí es estacionaria. Obtuvimos un p-valor de 0.01. Al ser menor a 0.05, rechazamos la hipótesis nula.

La serie no es estacionaria porque la media no es constante (posee tendencia). Por lo tanto, en el siguiente ejercicio (modelado), será obligatorio aplicarle transformaciones (diferenciación) para volverla estacionaria.



EJERCICIO 4. Haga modelos de predicción usando alguno de los modelos ARIMA (AR, MA, ARIMA o SARIMA)

- Transforme la serie para lograr que sea estacionaria en media y en varianza en caso de que no lo fuera.


la varianza era relativamente estable, la serie tenía una fuerte estacionalidad (anual) y una tendencia al alza (no estacionaria en media). Para corregir esto, aplicamos dos transformaciones:

- Diferenciación Estacional: Para remover el patrón de los meses.
 - Diferenciación Regular: Para remover la tendencia global restante.
- Verifique que las transformaciones lograron hacerla estacionaria en media, si no es así aplique otra diferenciación y verifique nuevamente.

Al aplicar ambas diferencias (regular y estacional), la prueba Dickey-Fuller Aumentada (ADF) nos arrojó un p-valor de prácticamente cero. Esto verifica que la transformación logró hacer la serie completamente estacionaria en media.

- Estime los parámetros del modelo. Utilice las funciones de autocorrelación y de autocorrelación parcial para esto.
- ACF (Autocorrelación): Vemos un pico negativo significativo en el rezago 1 (lag 1) que luego se corta. En los rezagos estacionales, hay un pico negativo muy fuerte en el rezago 12.
 - PACF (Autocorrelación Parcial): Vemos un decrecimiento gradual (cola) en los primeros rezagos y en los rezagos múltiplos de 12 (12, 24).
 - Estimación: Esto nos indica que el modelo ideal pertenece a la familia SARIMA.
- Entrene el modelo con los parámetros estimados y el conjunto de entrenamiento.
- Haga 2 modelos más, puede usar el autoarima de R si trabaja en R. Entrénelos con el conjunto de entrenamiento.
- Modelo 1 (Estimado manual): SARIMA
Este modelo incorpora la estimación que hicimos anteriormente (una diferenciación regular, una estacional y términos MA/SMA y AR en 1).
 - Modelo 2 (ARIMA estándar sin estacionalidad): ARIMA
Entrenamos este modelo únicamente para contrastar qué ocurre si usamos un ARIMA puro e ignoramos el patrón estacional.

- Modelo 3 (SARIMA optimizado): SARIMA
Jugando con los parámetros identificados, agregamos algo más de complejidad a las partes autorregresivas (AR).



EJERCICIO 5. Valide uno los modelos. Analice:

a) Contrastes sobre los coeficientes:

- Significación y raíces comunes.

- Coeficientes Significativos: Los términos ar.L1 (AR 1), ma.L1 (MA 1), ma.L2 (MA 2) y el término estacional ma.S.L12 (SMA 1) tienen un p-valor de 0.000. Al ser menores a 0.05, son estadísticamente significativos y aportan valor real al modelo.
- Coeficientes NO Significativos: El término ar.L2 tiene un p-valor de 0.688 y el término ar.S.L12 tiene un p-valor de 1.000. Esto indica que no son significativos de forma aislada.
- Análisis: La falta de significación en estos dos términos sugiere que el modelo tiene cierta sobre parametrización. Podríamos simplificar el modelo eliminando el segundo rezago autorregresivo regular y el autorregresivo estacional.

b) Diagnóstico:

- Este análisis se basa habitualmente en los residuos que no deben estar correlacionados con el pasado: su correlograma no debe tener ninguna correlación significativamente distinta de cero.

El análisis de residuos busca confirmar que el modelo ha capturado toda la información posible y que los errores sobrantes se comportan como "ruido blanco" (aleatorios y sin patrones).

- Correlograma (ACF de los residuos): En el gráfico inferior derecho, vemos que la inmensa mayoría de los rezagos caen dentro de la franja azul de confianza.


- Normalidad: El histograma y el gráfico Normal Q-Q muestran que los residuos siguen una distribución que se aproxima bastante a la normal, lo cual es un buen indicio de que los errores están bien balanceados, aunque con un leve sesgo.

c) Contrastes respecto a modelos alternativos

- Métricas AIC y BIC

Las métricas AIC (Criterio de Información de Akaike) y BIC (Criterio de Información Bayesiano) penalizan la complejidad del modelo; a menor valor, mejor modelo.

Aunque es el mejor modelo en términos de AIC, el diagnóstico de residuos (Ljung-Box) y los coeficientes no significativos nos invitan a reflexionar si este modelo es definitivo, o si se podrían afinar ligeramente los parámetros para el pronóstico final.



EJERCICIO 6. Haga una predicción usando el conjunto de prueba, y el mejor modelo determinado en el ejercicio anterior.

Para este paso, hemos entrenado el modelo SARIMA(2, 1, 2) x (1, 1, 1, 12) utilizando los datos hasta junio de 2023. Luego, le pedimos al modelo que pronostique los 36 meses siguientes (julio 2023 a junio 2026) y contrastamos


esta predicción (línea roja) contra los datos reales de prueba que habíamos reservado (línea verde).

Métricas de Error:

- RMSE (Error Cuadrático Medio): 0.8276 °C. Esta métrica penaliza los errores grandes. Nos indica que, en promedio, nuestras predicciones se desvían de la realidad en aproximadamente 0.82 °C.
- MAE (Error Absoluto Medio): 0.5775 °C. Esta es la desviación absoluta promedio.

Comportamiento del pronóstico:

- El modelo es excepcionalmente bueno para capturar el patrón estacional. Sabe perfectamente en qué meses la temperatura sube y en cuáles baja.
- Las predicciones (rojo) siguen de cerca a los datos reales (verde) y casi siempre se mantienen dentro del intervalo de confianza del 95% (área sombreada rosa).
- Podemos notar que a mediados de 2024 hubo un pico real de temperatura (línea verde muy alta) que el modelo subestimó ligeramente. Esto es normal en series climáticas, ya que fenómenos como El Niño pueden causar anomalías extremas que un modelo puramente autorregresivo no prevé si no se le alimentan variables exógenas. Aún así, el ajuste general es muy sólido.



EJERCICIO 7. Utilice otros modelos para predecir (holt winters, suavizamiento exponencial y seasonal naive). Compare resultados.


Modelo	RMSE (°C)	MAE (°C)
SARIMA (Ejercicio 6)	0.8276	0.5775

Holt-Winters	0.9442	0.7304
Seasonal Naive	0.9872	0.7973
Suav. Exponencial Simple	3.2050	2.7844

Análisis de los Resultados

- **Holt-Winters (Suavizamiento Exponencial con Tendencia y Estacionalidad):** Este modelo es el que más se acerca al rendimiento del SARIMA. Como la serie de tiempo tiene una estacionalidad anual (cada 12 meses) muy fuerte, Holt-Winters logra captar este patrón (línea roja punteada) y realiza predicciones cíclicas bastante certeras.
- **Seasonal Naive (Modelo Ingenuo Estacional):** Este modelo es sorprendentemente eficaz dada su simplicidad extrema. Lo que hace es simplemente tomar el último año de datos de entrenamiento y repetirlo tres veces hacia el futuro. Su RMSE de 0.98 °C demuestra que, en climatología, asumir que el próximo enero será idéntico al enero anterior es una base de predicción bastante decente.
- **Suavizamiento Exponencial Simple (SES):** Este modelo falla completamente para este conjunto de datos. Como puedes ver en la gráfica (línea amarilla horizontal), el SES solo genera una predicción "plana" que no tiene en cuenta la estacionalidad en absoluto. Su error cuadrático medio (RMSE) es enorme en comparación con el resto.

El modelo SARIMA (desarrollado en los ejercicios 4, 5 y 6) sigue siendo el mejor modelo evaluado para este conjunto de datos, logrando el margen de error más bajo.




EJERCICIO 8. Determine si su modelo es capaz de predecir valores actuales.

Para determinar si el modelo es capaz de predecir valores actuales, es necesario re-entrenarlo utilizando el 100% del conjunto de datos disponible (incluyendo tanto el entrenamiento como la prueba de los ejercicios anteriores). De este modo, la serie temporal llega hasta el mes pasado (junio de 2026), y nuestro próximo paso a pronosticar coincidirá exactamente con la fecha actual (julio de 2026) y el futuro a corto plazo.

Al ejecutar el modelo SARIMA(2,1,2)x(1,1,1,12) que resultó ganador en el análisis, obtenemos las siguientes proyecciones para los meses actuales:

- Julio 2026: 24.83 °C
- Agosto 2026: 24.87 °C
- Septiembre 2026: 24.36 °C
- Octubre 2026: 23.50 °C
- Noviembre 2026: 22.43 °C
- Diciembre 2026: 21.89 °C

El modelo es capaz de proyectar los valores actuales con éxito y muestra un grado de confiabilidad razonable. En la siguiente gráfica podemos ver cómo la línea roja continúa lógicamente el último tramo de la línea azul, manteniendo intacto el patrón estacional de la región (las bajadas cíclicas de temperatura a final de año y el alza hacia los meses de verano/primavera)



LINK DEL REPOSITORIO: <https://github.com/Dulce2004/CC3084-Data Science/tree/Hoja SeriesTiempo>