

Laboratorio 1

Series de Tiempo. Entrega Final

Integrantes:

231143 - Dulce Rebeca Ambrosio Jiménez


231177 - Daniel Alejandro Chet Delgado

231135 - Javier Alexander Linares Chang

Datos de uso exclusivamente académico; no corresponden a cifras oficiales del INGUAT ni del Instituto Guatemalteco de Migración.

1. Análisis exploratorio de datos

La base contiene 161,015 registros y 14 columnas (mes, vía, frontera, país, región, tipo de viajero y cantidad), sin nulos ni filas duplicadas, con 210 meses consecutivos de enero de 2009 a junio de 2026. La variable Viajero trae valores fraccionarios (estimados/prorrateados en parte), 54 registros en cero y ninguno negativo; en la limpieza previa se descartaron 21 filas con categorías inválidas en Región dos. La distribución por registro es fuertemente asimétrica a la derecha (mediana 7, media 324.6, máximo 92,336): no son errores, sino la mezcla de combinaciones de muy distinto volumen (tránsito terrestre masivo vs. llegadas puntuales de países lejanos), así que no se eliminan atípicos al agregar por mes ese efecto se integra naturalmente.




Izq.: total mensual (2009–jun. 2026), con la pandemia sombreada. Der.: patrón estacional agregado.

El total muestra tendencia creciente 2009–2019, desplome pandémico en 2020 y recuperación progresiva desde 2021 (2026 es parcial, solo enero–junio). La caída de 2023 no es una caída real de turismo: desde ese año Viajero excluye tránsito/comercio fronterizo de alta frecuencia, así que para comparar todo el período conviene usar Turista+Excursionista. El promedio por mes del año confirma una estacionalidad de período 12 clara, con picos en Semana Santa, mitad de año y diciembre.

Países, regiones, vías y fronteras. El top 3 de países acumulado es El Salvador, Guatemala y Estados Unidos de América — dominan los vecinos por tierra (tránsito) más el principal mercado aéreo de larga distancia. Por Región dos el top 3 es América Del Centro, América Del Norte y Europa. La vía Terrestre concentra 31,995,231 viajeros acumulados, la Aérea 19,063,103 y la

Marítima apenas 1,202,752; las tres fronteras principales son La Aurora (única vía aérea), Valle Nuevo y San Cristóbal (ambas terrestres, con El Salvador).




Izq.: top 15 países acumulados. Der.: viajeros por vía y top 10 fronteras.

2–3. División entrenamiento/prueba y construcción de series

La división es temporal (70/30, sin aleatorizar). En las series de 210 meses (Total, Vías, Turista, Excursionista, Viajero) el corte deja 147 meses de entrenamiento (ene-2009 a mar-2021) y 63 de prueba (abr-2021 a jun-2026); **Crucistas** es la excepción, con historia de solo 156 meses (deja de reportarse desde 2022), partida en 109/47 hasta dic-2021. El corte del 70% cae justo antes de la recuperación pospandemia, así que **todo el desplome de 2020 queda en entrenamiento y toda la recuperación en prueba** — una partición que condiciona buena parte de los resultados de la sección 4.

A partir del entrenamiento se construyeron ocho series mensuales: la obligatoria (**Total**) y dos categorías **Vías de ingreso** (Aérea, Terrestre, Marítima) y **Tipo de viajero** (Turista, Excursionista, Viajero, Crucistas, las cuatro categorías presentes en los datos).





División entrenamiento (70%) / prueba (30%) - Total mensual.

4. Análisis y modelado de cada serie

Para las ocho series se siguió el mismo procedimiento: no estacionariedad en varianza (componente estacional que crece con el nivel $\Rightarrow$ transformación $\log(1+p)$) y en media (ACF de decaimiento lento, ADF en niveles no rechaza en ninguna de las ocho); tras $d=1$ la ADF sí

rechaza en siete de las ocho (el caso límite se discute abajo). D (diferenciación estacional) se fija en 1 cuando la fuerza estacional de una descomposición STL supera 0.3, si no D=0. Con esos órdenes fijos se contrasta un modelo manual $(1,d,1)(1,D,1)_{12}$ — lectura típica de un ACF/PACF con decaimiento gradual — contra una búsqueda por AIC sobre 36 combinaciones (equivalente casero `deauto_arima`), y ambos contra Prophet, Holt-Winters, SES y seasonal naive, comparando MAE/RMSE sobre el conjunto de prueba real.

Ejemplo desarrollado: Total mensual




Izq.: descomposición (tendencia + estacional + residuo). Der.: ACF/PACF tras diferenciar ($d=1$, $D=1$).

Inicio 2009-01, fin de entrenamiento 2021-03 (147 obs.), frecuencia mensual. Tendencia (fuerza 0.79) y estacionalidad de período 12 (fuerza 0.39) con amplitud creciente $\Rightarrow$ no estacionaria en varianza; ADF en niveles no rechaza ($p=0.300$), tras $d=1$ sí ($p=0.0196$) $\Rightarrow$ no estacionaria en media, se usa $d=1$, $D=1$. El manual $(1,1,1)(1,1,1)_{12}$ da $AIC=74.5$; el grid-AIC prefiere **SARIMA(2, 1, 2)x(1, 1, 1, 12)** ($AIC=68.0$, de 36 combinaciones evaluadas) — algo más de estructura AR/MA que ayuda a explicar la recuperación abrupta post-pandemia dentro del propio entrenamiento. Pero su Ljung-Box **rechaza** ruido blanco en los tres rezagos ($p=0.003$, 0.0002 , 0.0003): buen AIC no implica residuos limpios. En la comparación final, **Prophet** gana con $RMSE \approx 107,269$ — un margen amplio sobre el SARIMA ($RMSE \approx 274,308$), porque modela la tendencia con puntos de quiebre en vez de extrapolar de forma rígida un régimen que ya cambió.

Resumen de las ocho series

Serie	d/D	Mejor SARIMA (grid-AIC)	AIC	Mejor modelo global	RMSE (prueba)
Total	1/1	SARIMA(2, 1, 2)x(1, 1, 1, 12)	68.0	Prophet	107,269
Vía Aérea	1/1	SARIMA(2, 1, 2)x(1, 1, 0, 12)	165.1	SES	41,350
Vía Terrestre	1/0	SARIMA(0, 1, 1)x(1, 0, 1, 12)	124.3	Prophet	71,292
Vía Marítima	1/1	SARIMA(0, 1, 2)x(1, 1, 1, 12)	505.8	SARIMA manual (1, 1, 1)x(1, 1, 1, 12)	604
Tipo Turista	1/1	SARIMA(0, 1, 0)x(1, 1, 0, 12)	40.3	SES	128,458
Tipo Excursionista	1/0	SARIMA(2, 1, 2)x(0, 0, 1, 12)	402.3	Prophet	22,414
Tipo Viajero	1/0	SARIMA(1, 1, 2)x(0, 0, 1, 12)	494.4	Prophet	31,875
Tipo Cruceristas	1/1	SARIMA(0, 1, 2)x(0, 1, 1, 12)	388.8	Prophet	9,064



Pronóstico del mejor modelo vs. valores reales de prueba, las ocho series.

Hallazgos que no están en la tabla. En **Vía Aérea** tanto el SARIMA manual como el de grid-AIC **explotan numéricamente** (MAE del orden de 10^{15} - 10^{20}): la doble diferenciación ($d=1$, $D=1$) en escala $\log_{1p}$ acumula deriva a lo largo de 63 meses de pronóstico, y al revertir $\text{conexp}(\cdot)$ esa deriva se vuelve una cifra sin sentido un buen AIC no garantiza un buen pronóstico a horizonte largo; ahí SES gana por descarte. En **Vía Marítima**, SARIMA manual, grid-AIC, SES y seasonal naive prácticamente empatan ($\approx 445/604$ MAE/RMSE): con el tramo final de entrenamiento en cero (cruceros parados), todos terminan pronosticando casi cero. En **Tipo Turista** el ADF tras $d=1$ queda apenas por encima de 5% ($p=0.0855$) caso límite que se mantiene con $d=1$ por consistencia con el resto de la categoría y porque el ACF/PACF diferenciado ya no muestra decaimiento lento. En general, **Prophet o SES ganaron en siete de las ocho series**: la partición 70/30 deja el choque pandémico de un lado y la recuperación del otro, y un modelo con puntos de quiebre de tendencia (o uno tan simple que no intenta extrapolar mucha estructura) generaliza mejor que un ARIMA ajustado a un régimen que ya cambió.

5. Análisis comparativo entre categorías

Categoría	Serie	Fuerza estacional	Fuerza tendencia	Volatilidad (CV)	Caída pandemia
Vías	Vía Aérea	0.57	0.79	0.33	-90.0%
Vías	Vía Terrestre	0.13	0.68	0.52	-94.8%
Vías	Vía Marítima	0.61	0.31	0.87	-100.0%
Tipo de viajero	Turista	0.47	0.79	0.38	-91.9%
Tipo de viajero	Excursionista	0.10	0.74	0.63	-98.6%
Tipo de viajero	Viajero	0.10	0.48	1.22	-89.9%
Tipo de viajero	Cruceristas	0.65	0.15	0.87	-100.0%

Vías. Mayor estacionalidad: **Marítima** (0.61) temporada de cruceros bien marcada, frente al 0.13 de Terrestre (tránsito cotidiano, no vacacional). Mayor tendencia: **Aérea** (0.79), el turismo de larga distancia que más ha crecido. Mayor volatilidad y más golpeada por la pandemia: **Marítima** otra vez (−100% abr–dic 2020) un sector que depende de barcos completos es más frágil que uno de miles de cruces individuales.

Tipo de viajero. Mayor estacionalidad: **Cruceristas** (0.65, mismo fenómeno que Marítima). Mayor tendencia: **Turista** (0.79). Mayor volatilidad: **Viajero** ($CV \approx 1.22$), aunque gran parte no es señal real de mercado sino el quiebre metodológico de 2023. Más afectada por la pandemia: **Cruceristas** (−100%).

Para INGUAT me quedo con tres ideas. Cruceros (Marítima/Cruceristas) es el segmento más estacional y más frágil ante choques externos conviene tratarlo aparte, no promediado con el tránsito terrestre. El tránsito terrestre, aunque es el que más volumen aporta, es también el menos estacional: buena parte no es turismo recreativo sino movimiento fronterizo cotidiano, así que separar "turismo real" de "tránsito" (Turista+Excursionista) es más útil que mirar el total agregado. Y para pronóstico: en la mayoría de las series ganó Prophet o SES sobre el SARIMA

con mejor AIC, porque un modelo con puntos de quiebre explícitos (o uno que no intenta extrapolar mucho) generaliza mejor después de un evento disruptivo que uno ajustado finamente a un régimen que ya cambió una lección más valiosa que cualquier MAE puntual para quien necesite proyectar después de la próxima crisis.

Conclusiones generales

Lo que más se me quedó dando vueltas de este laboratorio es que el mejor modelo casi nunca fue el más sofisticado: ajustamos SARIMA con búsqueda de AIC sobre 36 combinaciones por serie y aun así Prophet o SES ganaron en siete de las ocho, porque la partición 70/30 deja el desplome de 2020 en entrenamiento y la recuperación en prueba, y ningún ARIMA ajustado a datos previos al quiebre puede anticipar un cambio de régimen que todavía no había pasado. El caso de Vía Aérea donde el SARIMA no solo predijo mal, sino que explotó numéricamente lo dejamos documentado en vez de escondido porque es justo el tipo de error que vale la pena entender, no solo evitar. Esta base de datos tiene al menos tres quiebres estructurales encimados (pandemia, redefinición de "Viajero" en 2023, fin del reporte de "Crucevistas" en 2021), y cualquier modelo que no los tenga en cuenta de alguna forma con puntos de quiebre explícitos como Prophet, o simplemente sin intentar extrapolar mucho como SES tiene ventaja frente a un ARIMA que asume que la dinámica reciente se mantiene igual hacia adelante. La recomendación que nos llevamos como equipo: no confiar solo en el AIC para elegir modelo, porque mide qué tan bien se explica el pasado, no qué tan bien se anticipa un futuro que ya está cambiando.