

Laboratorio 2

Series de Tiempo con LSTM. Entrega Final

Integrantes:

231143 – Dulce Rebeca Ambrosio Jiménez

231177 – Daniel Alejandro Chet Delgado

231135 - Javier Alexander Linares Chang


Datos de uso exclusivamente académico; no corresponden a cifras oficiales del INGUAT ni del Instituto Guatemalteco de Migración.

1. Modelos LSTM (ejercicio 1)

Usamos los mismos conjuntos de entrenamiento y prueba del Laboratorio 1 (split temporal 70/30, sin aleatorizar) para dos series: Total mensual y Vía Aérea, elegidas porque en el Laboratorio 1 fueron los dos casos más difíciles para los modelos clásicos en Total, ningún SARIMA superó a Prophet porque el corte deja la caída de la pandemia en entrenamiento y la recuperación en prueba; en Vía Aérea, el SARIMA (manual y grid-AIC) explotó numéricamente al revertir una doble diferenciación logarítmica sobre 63 meses. Para cada serie se prepararon los datos con $\log_{1p}$ (misma transformación que en el Lab. 1) + escalado min-max (ajustado solo con entrenamiento) + ventanas supervisadas, y se tunearon 4 configuraciones LSTM que varían profundidad, tamaño de ventana (*look_back*), dropout y tasa de aprendizaje, todas con Adam, MSE y EarlyStopping. El pronóstico sobre los 63 meses de prueba es recursivo/walk-forward (el modelo nunca ve los valores reales de prueba), igual que ARIMA/Prophet/HW en el Laboratorio 1.


Config	Capas / unidades	look_back	dropout	lr
A simple	1 capa LSTM (32)	12	0.0	1e-3
B profunda	2 capas LSTM (64→32)	12	0.2	1e-3
C Ventana larga	1 capa LSTM (64)	24	0.1	1e-3
D lr bajo	2 capas LSTM (32→16)	18	0.1	5e-4

Total mensual



Total, mensual - las 4 configuraciones LSTM tuneadas vs. entrenamiento y prueba real.

Gana la config. A (simple, 1 capa, look_back 12, sin dropout) con $RMSE \approx 162,502$, por delante de B ($RMSE \approx 181,007$), C ($RMSE \approx 238,070$) y D ($RMSE \approx 271,283$). Con solo 147 observaciones de entrenamiento, la arquitectura con más capacidad (B) tiene más parámetros que ajustar y termina ajustándose más al ruido del entrenamiento que generalizando a prueba, mientras que el modelo más simple es el que menos sobreajusta. Aun así, ningún LSTM supera a Prophet ($RMSE \approx 107,270$ en el Laboratorio 1): la red no logra aprender un punto de quiebre de tendencia tan claro como el que Prophet modela explícitamente con sus *changepoints*.



Vía Aérea - las 4 configuraciones LSTM tuneadas vs. entrenamiento y prueba real.

Aquí gana D (2 capas $32 \rightarrow 16$, dropout 0.1, look_back 18, lr $5e-4$) con $RMSE \approx 55,424$, seguida de A ($RMSE \approx 59,128$) y B ($RMSE \approx 73,478$); C es la peor ($RMSE \approx 88,178$). A diferencia del SARIMA del Laboratorio 1 que explotó numéricamente (MAE del orden de 10^{15} - 10^{20}), el LSTM nunca diverge: su pronóstico recursivo opera sobre valores acotados en $[0,1]$, así que es mucho más estable como método, aunque no sea el más preciso. Aun así, SES sigue siendo mejor ($RMSE \approx 41,350$ contra 55,424 del LSTM).

1.4 — ¿Cuál predijo mejor? ¿Son mejores los LSTM que el Laboratorio 1?

Serie	Mejor Lab. 1	RMSE Lab. 1	Mejor LSTM	RMSE LSTM	LSTM vs. Lab. 1
Total mensual	Prophet	107,270	A (simple, lb12)	162,502	+51.5% peor
Vía Aérea	SES	41,350	D (2 capas, lb18, lr $5e-4$)	55,424	+34.0% peor

En ambas series el mejor modelo sigue siendo un modelo clásico del Laboratorio 1, no el LSTM, usando el mismo criterio para todos (MAE/RMSE sobre el mismo conjunto de prueba real). Tres razones lo explican. Tamaño de muestra: 147 observaciones de entrenamiento no alcanzan para que un modelo con muchos más parámetros que un SARIMA o un SES generalice mejor de hecho, en Total mensual la configuración que mejor generalizó fue la más simple de las cuatro


(A), lo que refuerza esta misma idea dentro del propio ejercicio. Naturaleza del quiebre: el problema central de estas dos series es un cambio de régimen estructural (la pandemia) que ocurre dentro del entrenamiento, pero cuya recuperación cae en prueba; Prophet lo modela explícitamente con puntos de quiebre, SES ni siquiera intenta extrapolar mucha estructura, y el LSTM solo aprende de los 147 meses que ve, sin mecanismo para anticipar un régimen que aún no ha ocurrido en esos datos. Ventaja real del LSTM: estabilidad. En Vía Aérea el SARIMA del Lab. 1 explotó numéricamente; ningún LSTM tuvo ese problema, porque su pronóstico recursivo está naturalmente acotado. Con series mensuales cortas (~150 observaciones) y quiebres estructurales grandes como la pandemia, los métodos clásicos con mecanismos explícitos para tendencia (Prophet) o simplicidad extrema (SES) superan a las LSTM tuneadas en este laboratorio la sección siguiente profundiza en qué hace a estas series parecidas o distintas entre sí, más allá del ejercicio de pronóstico.


2. Similitud entre series con catch22 (ejercicio 2)

2.1 ¿Qué es catch22 y por qué importa? catch22 nace de un problema concreto: el catálogo *hctsa* (Fulcher et al., 2013) calcula más de 7000 características por serie, pero muchísimas terminan midiendo variaciones del mismo fenómeno. Lubba et al. (2019) corrieron ese catálogo sobre miles de series de referencia y usaron selección greedy/clustering jerárquico para quedarse con el subconjunto más pequeño que mantiene casi el mismo poder de clasificación que las 7000 originales: 22 características, cada una representando una familia distinta de comportamiento dinámico casi sin redundancia — forma de la distribución, autocorrelación lineal, información mutua no lineal, periodicidad, valores atípicos, entropía simbólica y self-affinity/fractalidad. Para este laboratorio esto importa porque permite comparar 8 series de escalas y patrones muy distintos sobre un espacio común e interpretable, sin tener que comparar 8 gráficas a ojo.


Nota de reproducibilidad. El paquete oficial `pycatch22` no publica *wheels* para Windows y requiere compilar una extensión en C (Microsoft C++ Build Tools), no disponible en esta máquina. Las 22 características se reimplementaron en Python puro (numpy/scipy) siguiendo las definiciones publicadas `ver04_deep_learning_lstm/src/catch22_utils.py`.

2.2-2.5 Extracción, matriz y análisis. Se calcularon las 22 características para las 8 series completas del Laboratorio 1 (Total, 3 vías, 4 tipos de viajero — no solo entrenamiento, ya que este ejercicio compara series entre sí, no pronostica), se armó la matriz 8×22 y se estandarizó (z-score) antes de PCA, clustering, heatmap, correlación y distancias.







Izq.: PCA (PC1+PC2 explican 67.2% de la varianza). Der.: clustering jerárquico (Ward, k=3).



Heatmap de las 22 características catch22 (estandarizadas) por serie.





Izq.: correlación entre las 22 características (a través de las 8 series). Der.: mapa de distancias entre series.

2.6-2.13 Análisis e interpretación

2.7 Series más similares. El par más cercano de toda la matriz es Total mensual y Vía Terrestre (distancia≈4.3): Vía Terrestre domina el volumen total, así que dinámicamente son casi la misma serie. Junto a ellas, en el mismo cluster jerárquico, caen Vía Aérea y Tipo Turista.

2.8 Características más importantes para diferenciar. En PC1 (46.2% var.)

dominanCO_flecac, SC_FluctAnal_2_dfa...,

SP_Summaries_welch_rect_centroid,FC_LocalSimple_mean1_taurusrat y

SP_Summaries_welch_rect_area_5_1 miden qué tan persistente/suave es la autocorrelación y qué tan concentrada está la energía espectral en frecuencias bajas. En PC2 (20.9% var.) dominan

PD_PeriodicityWang_th0_01,CO_FirstMin_ac,

FC_LocalSimple_mean3_stderr,SB_BinaryStats_diff_longstretch0 e

IN_AutoMutualInfoStats_40_gaussian_fmmi más relacionadas con periodicidad y memoria de corto plazo.

2.9 Grupos naturales. Sí, tres clusters (Ward, k=3): (1) Total, Vía Aérea, Vía Terrestre, Tipo Turista alto volumen, tendencia fuerte (0.68-0.79), caída de pandemia severa pero parcial (-90% a -95%); (2) Vía Marítima y Tipo Cruceristas tendencia débil (0.15-0.31), estacionalidad marcada (0.61-0.65) y caída de pandemia total (-100%); (3) Tipo Viajero y Tipo Excursionista menor volumen, volatilidad más alta de las 8 series (CV 0.63-1.22) y estacionalidad casi nula (0.10, 0.096).


2.10 ¿Las series de una misma categoría se agrupan? No necesariamente uno de los hallazgos más interesantes: las 3 vías quedan repartidas en dos clusters distintos (Aérea/Terrestre en uno, Marítima sola en otro), y los 4 tipos de viajero quedan repartidos en los tres clusters. La etiqueta categórica del Lab. 1 no predice bien el comportamiento dinámico; lo que agrupa realmente es el perfil de volumen/volatilidad/impacto de pandemia.

2.11 Serie más atípica. Tipo Cruceristas: mayor distancia promedio a las demás (≈8.1), la serie más corta (156 meses en vez de 210), caída de pandemia total y la volatilidad más alta junto con Marítima (CV≈0.87) la categoría más nueva, de menor volumen, y la que más tardó en recuperar actividad tras el cierre de puertos.

2.12 Comparación con el EDA tradicional. Los agrupamientos son, en general, consistentes: el cluster (2) concentra la caída de pandemia total y la mayor volatilidad; el cluster (1) concentra la tendencia más fuerte (STL). Hay matices en estacionalidad Marítima calza con su cluster por estacionalidad alta (0.61), pero Cruceristas comparte cluster con ella más por la caída total de pandemia que por estacionalidad. Las funciones de autocorrelación del Lab. 1 (más persistentes en Total/Vías, más cortas en Viajero/Excursionista) calzan directamente con las cargas de PC1 (CO_flecac, CO_FirstMin_ac), literalmente medidas de autocorrelación.

2.13 Descubrimientos no evidentes en el EDA tradicional. (1) Las etiquetas categóricas del Lab. 1 no son buenos predictores de similitud dinámica el agrupamiento real corta transversalmente esas categorías. (2) Total mensual y Vía Terrestre son casi indistinguibles dinámicamente (la distancia más chica de toda la matriz) se intuía por el peso de Vía Terrestre, pero nunca se había cuantificado. (3) Tipo Viajero y Tipo Excursionista cargan fuerte y en la misma dirección sobre PC2 (periodicidad/memoria corta), revelando un tipo cualitativamente distinto de dependencia temporal que no se nota comparando ACF/PACF una serie a la vez. (4) La correlación casi perfecta entre pares de características con nombres muy distintos (SB_MotifThree_quantile_hhy SB_TransitionMatrix_3ac_sumdiagcov, $r \approx -0.99$) muestra que buena parte de las 22 características son redundantes para estas 8 series.

2.14 LSTM + características catch22



Total mensual — LSTM con y sin características catch22.

Se construyó un LSTM de dos ramas para Total mensual: la secuencia entra a una LSTM apilada (64→32, dropout 0.2, la misma configuración que ganó como mejor LSTM "puro" para esta serie), y el vector estandarizado de 22 características catch22 entra por una rama densa aparte; ambas ramas se concatenan antes de la salida. El resultado no mejoró al mejor LSTM puro: RMSE≈238,890 contra 162,502 de la config. A (y 107,270 de Prophet). La razón es directa: el vector catch22 es un solo vector fijo por serie, así que se repite idéntico en las 135 ventanas de entrenamiento no aporta información que varíe en el tiempo, solo agrega parámetros que hay que ajustar con las mismas 147 observaciones de siempre, es decir, más riesgo de sobreajuste sin beneficio real. Esta idea sí tendría sentido en un modelo global entrenado con las 8 series a la vez, donde el vector catch22 variaría entre ejemplos y el modelo podría aprender a condicionar su pronóstico según el perfil dinámico de cada serie pero eso queda fuera del alcance de comparar contra el mejor LSTM de una sola serie, que es lo que pide el ejercicio.

Conclusiones generales

Entre los dos ejercicios la conclusión que más se repite es que más complejidad no es lo mismo que mejor desempeño: en el ejercicio 1, ningún LSTM tuneado superó a Prophet o SES en las dos series evaluadas, porque con series mensuales cortas y un quiebre estructural grande como la pandemia, un modelo con mecanismos explícitos para tendencia (Prophet) o incluso sin memoria de mediano plazo (SES) generaliza mejor que una red recurrente que solo aprende de los 147 meses que ve. La ventaja real del LSTM no fue precisión sino estabilidad numérica nunca explotó como sí lo hizo el SARIMA del Laboratorio 1 en Vía Aérea. En el ejercicio 2, catch22 resultó una herramienta más reveladora de lo esperado: los agrupamientos que arma a partir de solo 22 números por serie coinciden en gran medida con lo que ya sabíamos del EDA (tendencia, volatilidad, impacto de pandemia), pero además muestra algo que el análisis por categoría del Laboratorio 1 no dejaba ver que las etiquetas nominales (vía de ingreso, tipo de viajero) no predicen bien el comportamiento dinámico de una serie, y que lo que realmente importa es su perfil de volumen, volatilidad y respuesta a la pandemia. Usar esas características dentro de un LSTM (2.14) confirmó, de forma indirecta, que agregar información estática a un modelo con muy pocos datos de una sola serie no ayuda por sí sola el beneficio de catch22 en este laboratorio estuvo en la fase de análisis y comparación entre series, no en la fase de pronóstico de una serie individual.